

電商分眾決策模擬系統 | 廖若閔



以雙層漏斗機器學習架構與動態決策門檻，從 9 萬名電商訪客的瀏覽與購物車行為中識別加車與購買意圖，將流失用戶精準分層挽回——以數據驅動取代一刀切補貼陷阱。



技術標籤：Google Analytics 4 · BigQuery ML · Dataform · Python · Looker Studio · XGBoost

專案概述 (Project Overview)

背景與問題定義 (Business Problem)

傳統電商行銷在挽回流失用戶時，常對所有「購物車未結帳」的受眾一律發放優惠券。這種「一刀切」的盲目補貼忽視了消費者漏斗深度的差異：意圖模糊的低潛力族群往往消耗最多預算、卻產生極低的真實轉換，導致利潤被補貼浪費（Cannibalization）侵蝕。

本專案建構高精準度的雙漏斗轉換預測模型。有別於黑箱做法，結合四篇消費者心理學與機器學習理論文獻，建構端到端的 MLOps「雙漏斗階段（預測加車 → 預測購買）」分層建模策略。以模型機率門檻（F1-max）為分群邊界，並將手法選擇與成本經濟拆成獨立的下游層（避免門檻與手法的循環依賴），把流失用戶分為三個受眾層，依各層特性（成交接近度、價值、規模）配對差異化的介入，避免對低意圖用戶無效補貼。



核心商業洞察 (Key Insights)

- 雙漏斗驅動機制截然不同，由 EDA 與 SHAP 雙重驗證。

EDA 顯示上層關鍵特徵在高低分層間差距達近 4-7 倍（瀏覽商品數 6.6×、跨類別 6.9×、單品重複 6.7×、停留時間 3.8×），遠大於下層的約 2-2.2 倍。SHAP 進一步確認質性差異：上層由「瀏覽分類廣度」單一主導（SHAP $\approx$ 0.22，為第二名約 3.4 倍），第二名為「是否回訪客」（ $\approx$ 0.065）；item_focus_ratio 降至第 6（0.033）。下層由「購物車平均單品數量」主導（SHAP $\approx$ 0.175），第二名為「MAXREP（單品最大重複瀏覽數）」（ $\approx$ 0.115）；總互動時間降至第 5（0.048），反映購買由「商品考量廣度 + 單品反覆猶豫」雙引擎驅動。兩者預測結構差異是拆分建模的核心依據。

- 漏斗階段 × 成交摩擦決定最適介入工具，而非一律補貼高分族群。

- 配置原則：介入強度 $\propto$ 需要克服的摩擦，且只投在夠有反應的層。
- 購買漏斗：高潛力（ > 0.50 ）自然購買率已達 60%、最接近成交，只需零成本提醒信輕觸（對最可能自己回頭的人灑券 = 補貼本來就會買的人）；中潛力（0.30-0.50）仍猶豫，改發免運券移除「運費痛點」這個結帳放棄主因。
- 加車漏斗：高潛力自然購買率 11%、中潛力 7%；把最強的價格槓桿（9 折券）集中於意圖最強的高潛力層（自然購買率 11%，最保守毛利假設下 uplift +5.5pp 即打平，見分眾策略推導），中潛力採較輕的免運／觀察。
- 兩漏斗低潛力皆不投（自然轉換極低，補貼 ROI 無法正當化）。
這個「依成交摩擦配對手法、把預算留給有反應的層」的設計，正是本專案區別於「高分即發券」一刀切的核心邏輯。

- 雙漏斗統一採用 XGBoost；Purchase 漏斗 RF 效能更強但以架構一致性入選。

加車漏斗 XGBoost ROC-AUC（0.79）、Log Loss（0.47）均最佳，是明確選擇。購買漏斗 RF ROC-AUC（0.83）優於 XGBoost（0.78）達 0.05，RF 為真正效能最強者；選 XGBoost 純為統一 MLOps 管線，此為已知折衷，後續可改以 RF 部署下層。

資料來源與分析範圍 (Data & Scope)


- 資料集介紹：本專案使用 Google BigQuery 公開資料集，原始資料來自 Google 自家電商平台（Google 周邊商品店）的真實用戶行為紀錄，由 Google 官方釋出供公眾研究使用，數值經過部分模糊化處理以保護用戶隱私。
- 資料格式與時間範圍：為 Google Analytics 4（GA4）事件流，每一筆紀錄代表一個用戶在網站上的一個動作——包含瀏覽頁面、查看商品、加入購物車、進入結帳、完成購買等。資料涵蓋 2020 年 11 月至 2021 年 1 月，橫跨黑色星期五、聖誕節等電商旺季，共追蹤超過 85,000 名活躍用戶的完整購物路徑。

- **巢狀資料結構**：有別於整理好的結構化表格，GA4 原始資料是巢狀的事件序列——每位用戶的每個動作都是一筆獨立事件，特徵工程的第一步就是從這些原始事件中提取有意義的行為特徵（如跨 Session 的瀏覽廣度、單品重複檢視次數、購物車金額等），再送入模型訓練。
- **Scope 決策**：初步 EDA 顯示美國單一市場佔整體流量約 43%，且貢獻絕大部分營收。本專案聚焦美國市場，在最大化商業代表性的同時，確保模型訓練資料的一致性，避免多市場混訓帶入不必要的特徵噪音。

🔧 技術架構與資料管線 (Data Pipeline)

本專案建立具備高自動化與防禦性的機器學習管線，將龐雜的 GA4 原始事件資料轉化為可落地的商業決策引擎：

- 資料清洗與特徵工程 (Dataform / SQLX)：進行資料去噪，針對缺失值和極端值執行標準化，處理特徵共線性問題。
- 雙軌預測模型與可解釋性 (BigQuery ML & SHAP)：針對不同漏斗階段部署不同 XGBoost 模型，並導入 SHAP 演算法解開黑盒子，量化促成轉換的關鍵特徵。
- 嚴格防漏機制 (Data Leakage Prevention)：
 - 時序資料切分 (Time-Series Split)：將資料嚴格劃分為互不重疊的訓練集（2個月）、驗證集（3週）與獨立盲測集（10天），確保所有商業效益預估皆來自未知的未來流量。
 - 截斷點機制 (Time Cutoff)：以目標行為發生時間點作為「觀察終止線」，嚴格拋棄該點後的所有行為特徵（上層以 `MIN(add_to_cart)` 為界，下層以 `MIN(begin_checkout OR purchase)` 為界），確保預測邏輯符合真實世界的因果關係。



附圖：Dataform DAG / 架構流程圖

基於消費者行為理論的特徵工程 (Feature Engineering)

核心策略與理論基礎 (Theoretical Foundation)

- 1. 雙漏斗分層建模 (Dual-Funnel Strategy)
 - **策略**：上漏斗預測「加入購物車」（全體活躍用戶），下漏斗預測「最終購買」（僅限已加車用戶）。
 - **理論支持**：根據 Kukar-Kinney & Close (2010) 的研究，消費者加入購物車常出於「比價」或作為「願望清單（組織工具）」，並非完全等同於購買意圖。分層過濾能有效排除純比價或組織性質的雜訊，聚焦具備真實轉換潛力的用戶。

關鍵特徵矩陣與工程實作 (Key Feature Matrix & Engineering)

為了精準捕捉用戶意圖並確保模型的泛化能力 (Generalization)，本專案在特徵工程上嚴格執行了防範資料洩漏 (Data Leakage) 與處理共線性 (Collinearity) 的雙漏斗特徵篩選機制。特徵矩陣涵蓋以下四大維度：

- ### 📌 歷史價值與基礎活躍度 (Historical Value & Baseline Activity)

- 應用特徵：`log_historical_session_count`，`days_in_dataset`，`session_frequency_per_day`，`is_returning_user`
- 策略與商業邏輯：
 - 參考 Wu 等人 (2021) 的 Improved RFM 模型概念，將傳統的絕對數值轉化為「觀察期活躍天數 (`days_in_dataset`)」與「每日平均造訪頻率 (`session_frequency_per_day`)」。
 - 工程亮點：上下漏斗皆納入此維度作為判斷用戶基礎轉換機率的基準。將絕對次數轉化為比例 (Ratio)，能大幅提升特徵對未來數據的泛化能力。

🔗 瀏覽脈絡與意圖收斂 (Navigational Context & Intent Convergence)

- 應用特徵：`log_unique_categories_viewed`，`log_total_value_viewed`
- 策略與商業邏輯：
 - Moe (2003) 指出，廣泛瀏覽多個分類（高類別多樣性）通常屬於早期的「探索型」買家，而進入結帳階段的高意圖買家則會展現出極低的分類瀏覽廣度。
 - 工程亮點 (降噪策略)：完美實踐行為收斂理論。在上漏斗保留分類數與總價值以捕捉探索廣度；但在下漏斗 (已加車) 果斷剔除此特徵，防止廣泛的瀏覽總覽與高純度的購物車特徵產生共線性，避免稀釋權重。

🔗 購物車明細與價格摩擦力 (Cart Details & Price Friction)


- 應用特徵：`log_user_total_cart_value`，`log_unique_items_in_cart`，`log_cart_count`，`log_avg_price_viewed`
- 策略與商業邏輯：
 - Kukar-Kinney & Close (2010) 的研究證實，消費者在結帳前對「訂單總成本」的擔憂，以及評估總價後的「等待降價」心理，是導致購物車放棄的核心摩擦力。
 - 工程亮點 (下漏斗專屬)：嚴格遵守時間截斷點，上漏斗排除 `log_cart_count` 等特徵以防資料洩漏 (Data Leakage)；在下漏斗將購物車含金量作為必備強訊號，並透過 LR 模型中的 L2 正規化 (Ridge) 吸收這些變數間的高度共線性。

🔗 深度互動與單品猶豫度 (Depth & Item Consideration)

- 應用特徵：`log_max_item_rep_sessions`，`log_max_item_rep_views` (即 MAXREP)，`log_page_view_count`，`pages_per_session`
- 策略與商業邏輯：
 - 結合 Sakar 等人 (2018) 對網頁互動深度指標的應用，以及 Moe (2003) 提出的「單品最大重複檢視次數 (MAXREP)」作為預測目標導向購買的關鍵指標。
 - 工程亮點 (考慮期深度捕捉)：`MAXREP` 捕捉了用戶跨 Session 或同 Session 反覆查看單一商品的猶豫行為。數據顯示其在上漏斗極度稀疏 (1.52%)，但在下漏斗成為強勢特徵 (21.3%)。此外，上漏斗透過 `pages_per_session` 防禦了 `page_view` 絕對值的共線性；下漏斗則因意圖收斂，放回絕對值以提供模型額外的行為訊號。

資料分布特性

大部分數值特徵呈現極端右偏分布，因此在模型訓練前對所有數值特徵進行 Log 轉換。



用戶行為深度剖析

在探索性資料分析 (EDA) 階段，我發現用戶行為特徵隨漏斗推進，呈現顯著的「意圖斷層」——驅動加車的信號與驅動購買的信號，本質上屬於兩種不同的行為維度：



上層漏斗（未加車 → 加車）：「探索廣度」的初步爆發

- 關鍵差異：跨類別瀏覽擴張 8.4 倍（0.27 → 2.27 個品類）；每次造訪瀏覽商品數成長 16 倍（0.39 → 6.27 項）；單品重複瀏覽次數增加 8.8 倍（0.39 → 3.43 次）；總停留時間增加 5.7 倍（55.19 → 311.76 秒）。
- 行為特徵：密集的跨品類商品探索，反映購買意圖從無到有的量化積累。值得注意的是，加車者的每日造訪頻率反而較低（1.19 → 0.92）——意圖不是靠「更頻繁回訪」堆出來，而是靠單次造訪內更深的探索。

下層漏斗（加車棄單 → 最終購買）：「承諾深度」與購物車經濟規模的擴張

- 關鍵差異：雖然兩者皆已加車，但最終購買者的每次造訪瀏覽商品數增加 2.3 倍（4.72 → 10.78 項）；購物車不重複商品數擴張 2.2 倍（38.41 → 83.55 項）；購物車總金額擴張 2.3 倍（\$1,022.23 → \$2,307.47 USD）；總停留時間增加 2.1 倍（456.26 → 951.72 秒）。
- 行為特徵：從單純的商品比較轉向具體購買承諾，呈現沉沒成本累積（更高瀏覽強度）與主動擴張購物車規模同步發生的模式。同樣地，購買者的每日造訪頻率低於棄單者（0.93 vs 1.1）——他們用更少、更集中的 session 完成決策，而非反覆回訪。

💡 一個跨漏斗的反直覺信號：承諾深度 ≠ 造訪頻率

兩個漏斗都呈現同一個模式：轉換者的每日造訪頻率反而低於未轉換者（加車 0.92 vs 未加車 1.19；購買 0.93 vs 棄單 1.1）。換言之，頻繁回訪不代表高意圖——反覆回訪卻不出手，更像是猶豫或比價；真正會轉換的人，是在單次造訪內投入更深（更高停留時間、更廣探索、更大購物車），而非靠造訪次數累積。

💡 漏斗拆分決策

拆分的實證前提：加車離購買並不近。有 add_to_cart 事件的 5,603 名用戶中，最終購買僅 1,304 人——加車 → 購買轉換率 23.3%（以原始 cohort 統計，母群定義為有 add_to_cart 事件的美國用戶，未套用建模的流量來源/裝置過濾條件），即 77% 的加車者棄車，與業界長期約七成的棄車率一致（建模 cohort 採擴充加車定義後為 24.1%，兩者接近，顯示 cohort 過濾及定義調整未扭曲母體的轉換結構）。加車不是購買的前廳，而是另一道獨立的決策關卡。

EDA 進一步驗證：上下漏斗的驅動力截然不同。若將所有用戶丟進單一模型，會面臨嚴重的特徵衝突（Feature Conflict）。以合成的「單品專注度（Item Focus Ratio）」為例，在上層漏斗，專注度從 0.75 提升至 1.0，是確立加車意圖的強信號（找到想買的目標）；但下層漏斗方向相反——最終購買者僅 0.70，棄單者反而 0.92，因為意圖已轉化為行動，注意力從單品轉移至跨頁面的結帳流程、運費計算與加購。相同特徵在不同階段預測方向完全相反，單一模型會互相抵銷權重——雙漏斗架構正是為了解決這個行為斷層。

另一個常見質疑是：為什麼不直接做單一購買預測模型、把加車行為當特徵？因為上層模型的服務對象是尚未加車的用戶——在 118,000+ 名活躍用戶中，經加車完成購買者僅 1,304 人（約 1.1%），對未加車母群而言購買是極稀有事件，單一模型幾乎沒有正類可學，且其輸出無法對接「推進加車」這個行動。兩階段拆解讓每個模型都有可學習的 base rate（加車 ~23%、加車後購買 ~24%），且每個輸出各自對接一個明確的營運決策。

▼ 特徵動態調整與共線性處理 (Feature Convergence)

為分析特徵共線性對模型的潛在影響，對上下層漏斗的訓練集（TRAIN + VALIDATION）分別執行 Pearson 相關係數矩陣分析。

上層漏斗															feature_y / correlation	
feature_x	總瀏覽商品...	總互動時間...	總互動事件數	總啟動工作...	瀏覽商品總...	瀏覽商品最...	瀏覽不重複...	瀏覽商品平...	用戶生命週...	每次造訪平...	歷史造訪次數	單品最大跨...	每次造訪平...	每日平均造...		
單品最大總...	0.56	0.62	0.39	0.32	0.87	0.42	0.62	0.3	0.23	0.15	0.32	0.59	0.27	-0.04		
單品最大跨...	0.35	0.47	0.35	0.45	0.52	0.59	0.6	0.54	0.31	0.12	0.45	-	0.11	-0.05		
瀏覽不重複...	0.52	0.69	0.45	0.34	0.69	0.59	-	0.33	0.26	-	-	-	-	-		
每次造訪平...	0.68	0.44	0.83	-0.08	0.23	0.03	0.27	0.01	-0.04	0.99	-	-	-	-		
歷史造訪次數	0.2	0.37	0.26	0.69	0.33	0.23	0.34	0.13	0.6	-0.07	-	-	-	-0.08	0.03	
每次造訪平...	0.82	0.44	0.87	-0.07	0.14	0.02	0.22	0.02	-0.03	-	-	-	-	-	-	
瀏覽商品總...	0.57	0.65	0.41	0.33	-	-	-	-	0.24	-	-	-	-	-	-	
總互動事件數	0.9	0.69	-	0.26	-	-	-	-	-	-	-	-	-	-	-	
瀏覽商品平...	0.06	0.17	0.08	0.13	0.32	0.81	-	-	0.11	-	-	-	-	-	-	
瀏覽商品最...	0.15	0.33	0.14	0.23	0.45	-	-	-	0.18	-	-	-	-	-	-	
用戶生命週...	0.14	0.26	0.18	0.59	-	-	-	-	-	-	-	-	-	-	-	
總互動時間 (...)	0.67	-	-	0.37	-	-	-	-	-	-	-	-	-	-	-	
總啟動工作...	0.19	-	-	-	-	-	-	-	-	-	-	-	-	-	-	
每日平均造...	-0.05	-0.06	-0.07	0.03	-0.05	-0.04	-0.08	-0.04	-0.56	-0.08	-	-	-0.05	-	-	

上層漏斗 (預測加車)：特徵共線性診斷與修剪策略

階段行為特徵：探索與發散 (Window Shopping)

上層漏斗的用戶尚未建立明確的購買意圖，行為以廣泛點擊與瀏覽為主。特徵間的共線性主要來自於「整體活躍度的重疊」與「衍生計算特徵的數學關聯」。為確保羅吉斯迴歸權重穩定與 XGBoost 訓練效率，執行以下特徵修剪。

特徵修剪清單 (Pruning Strategy)

針對相關係數 > 0.80 的高共線性群組，採取「保留商業解釋力最強者，剷除絕對冗餘」的原則：

- 基礎流量計數 (系統冗餘)
 - ✓ 保留：`historical_session_count` (歷史深度)
 - ✗ 剷除：`count_session_start` (與歷史造訪相關性達 0.99)
- 瀏覽活躍度群組 (高度重疊)
 - ✓ 保留：`view_item_count` (商品瀏覽總數)、`view_items_per_session` (單次造訪瀏覽商品深度)
 - ✗ 剷除：`count_engagement` (與瀏覽總數相關性 0.90)、`pages_per_session` (與單次瀏覽商品深度相關性 0.96)
- 價格與價值群組 (定錨與數學陷阱)
 - ✓ 保留：`avg_price_viewed` (穩定反映用戶消費力/預算帶)
 - ✗ 剷除：`max_price_viewed` (與平均價格相關性 0.81)、`total_value_viewed` (與單品重複瀏覽數產生 0.87 的數學乘數共線性)

特徵對齊與衍生策略 (Alignment & Engineering)

為確保上（預測加車）、下（預測購買）兩層漏斗的模型架構與特徵空間一致，將同步套用下漏斗的比例轉換邏輯：

- 衍生單品專注度 (Item Focus Ratio)：
 - 公式：`max_item_rep_views / view_item_count`
 - 策略意義：雖然在上層漏斗中，MAXREP 與總瀏覽數的相關性僅中等 (0.56)，代表其本身就是良好的獨立訊號，但轉換為 Ratio (0~1 之間) 能完美量化「發散探索」與「聚焦考慮」的切換點，並維持雙漏斗模型的特徵一致性。

下層漏斗																feature_y / correlation	
feature_x	總瀏覽頁面次數	購物車總金額	總瀏覽商品次數	購物車不重複	總互動時間 (秒)	瀏覽商品最高	每次造訪平均	每次造訪平均	用戶生命週期	歷史造訪次數	單品最大跨 5	單品最大總量	平均單次造訪	瀏覽商品平均	購物車平均單	每日平均造訪	單品集中度
單品最大總量	0.68	0.61	0.86	0.66	0.63	0.39	0.49	0.66	0.26	0.3	0.49	-	0.51	0.14	0.07	-0.06	-0.24
加車總次數	0.4	0.99	0.59	0.99	0.44	0.29	0.33	0.51	0.1	0.14	0.24	0.66	0.41	0.04	0.04	0	-0.25
平均單次造訪	0.53	0.34	0.57	0.41	0.89	0.3	0.84	0.81	-0.08	-0.15	-	-	-	0.04	0	-0.03	-
每次造訪平均	0.53	0.42	0.72	0.51	0.51	0.3	0.85	-	-0.08	-	-	-	-	0.02	0.02	-	-
單品最大跨	0.52	0.24	0.47	0.24	0.41	0.29	-0.01	0.01	0.51	0.66	-	-	-0	0.13	0.01	-0.06	-0.21
每次造訪平均	0.64	0.27	0.6	0.32	0.53	0.3	-	-	-0.09	-	-	-	-	0.06	-0.03	-	-
總互動時間 (s)	0.79	0.37	0.76	0.43	-	-	-	-	-	-	-	-	-	-	0	-	-
瀏覽商品最	0.41	0.36	0.41	0.29	0.36	-	-	-	0.2	-	-	-	-	-	0.05	-	-
歷史造訪次數	0.45	0.14	0.32	0.13	0.32	0.25	-0.18	-0.15	0.63	-	-	-	-	0.1	0.02	0.02	-
總瀏覽商品	0.86	0.5	-	0.58	-	-	-	-	-	-	-	-	-	-	0.02	-	-
瀏覽商品平均	0.09	0.25	0.05	0.04	0.06	0.62	-	-	0.08	-	-	-	-	-	-0.06	-	-
用戶生命週期	0.32	0.1	0.25	0.1	0.23	-	-	-	-	-	-	-	-	-	0.01	-	-
購物車不重	-	0.6	-	-	-	-	-	-	-	-	-	-	-	-	0.1	-	-
總瀏覽頁面	-	0.33	-	0.38	-	-	-	-	-	-	-	-	-	-	-0.02	-	-
購物車平均	-	0.1	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
每日平均值	-0.02	-0.01	-0.03	0	-0.02	-0.06	-0.03	-0.03	-0.54	-	-	-	-	-0.03	-0.01	-	-
單品集中度	-0.44	-0.17	-0.44	-0.23	-0.37	-0.24	-0.37	-0.37	-0.14	-0.16	-	-	-0.33	0.08	0.08	0.05	-

📊 下層漏斗：特徵共線性診斷與優化策略

💡 核心現象：意圖收斂 (Intent Convergence)

進入下層漏斗（已加車）後，用戶目的性極強，行為呈現高度線性。這導致許多在上層漏斗看似獨立的特徵，在下層漏斗發生了數學上的重疊（結構性共線性），必須進行特徵修剪以防模型權重撕裂或浪費決策樹深度。

✂️ 特徵修剪清單 (Pruning Strategy)

針對相關係數 > 0.85 的重災區，採取「保留代表性特徵，剷除絕對冗餘」策略：

- 購物車維度 (相關性 0.89 ~ 0.99)
 - ☒ 保留：`user_avg_items_per_cart` (複雜度)、`user_total_cart_value` (含金量)
 - ☒ 剷除：`cart_count`、`unique_items_in_cart` (因多數用戶單次加車即為 1 件獨立商品，提供 99% 重複資訊)
- 活動量 (相關性 0.79 ~ 0.86)
 - ☒ 保留：`total_engaged_time_seconds` (最通用的 engagement 代表,涵蓋頁面與商品瀏覽)
 - ☒ 剷除：`view_item_count`、`page_view_count` (訊號重疊)
- 單次造訪強度 (相關性 0.84 ~ 0.85)
 - ☒ 保留：`view_items_per_session` (與 total_engaged 量綱不同(商品/次),不重複)
 - ☒ 剷除：`pages_per_session`、`avg_session_engaged_time_seconds` (訊號重疊)

🧠 新增衍生特徵：單品專注度 (Item Focus Ratio)

針對 `max_item_rep_views` 與 `view_item_count` 之間高達 0.86 的共線性，採用比例轉換降維：

- 公式：`max_item_rep_views / view_item_count`
- 商業意義：數值越接近 1，代表用戶越死心塌地專注於單一商品（極高購買意圖）；數值越低，代表仍在多個商品間猶豫徘徊。此特徵能有效消除絕對值帶來的共線性干擾。

▼ 點此展開：「特徵工程」完整 SQLX 原始碼

```
config {
  type: "table",
  schema: "ga4_ml_us",
  name: "ga4_features_cart",
  description: "GA4 用戶行為特徵表：預測加車專用",
  dependencies: ["user_identity"],
}

WITH Raw_Data AS (
  SELECT
    *,
    (SELECT value.int_value FROM UNNEST(event_params) WHERE key = 'ga_session_id') AS ga_session_id,
    (SELECT value.int_value FROM UNNEST(event_params) WHERE key = 'engagement_time_msec') AS engagement_time_msec
  FROM `bigquery-public-data.ga4_obfuscated_sample_ecommerce.events_*`
  WHERE _TABLE_SUFFIX BETWEEN '20201101' AND '20210131'
  AND geo.country = 'United States'
),
User_Cutoff_Times AS (
  SELECT
    user_pseudo_id,
    MIN(CASE WHEN event_name = 'add_to_cart' THEN event_timestamp END) AS cutoff_timestamp
)
```

```

FROM Raw_Data
GROUP BY user_pseudo_id
),
Filtered_Events AS (
SELECT e.*
FROM Raw_Data AS e
LEFT JOIN User_Cutoff_Times AS c
ON e.user_pseudo_id = c.user_pseudo_id
WHERE c.cutoff_timestamp IS NULL
OR e.event_timestamp < c.cutoff_timestamp
OR (e.event_timestamp = c.cutoff_timestamp AND e.event_name != 'add_to_car
t')
),
Base_Users AS (
SELECT
user_pseudo_id,
MAX(event_timestamp) AS last_interaction_timestamp,
MAX(PARSE_DATE('%Y%m%d', event_date)) AS last_interaction_date, -- 觀測窗
口末日 (供 days_in_dataset / 頻率, 非 split)
MIN(PARSE_DATE('%Y%m%d', event_date)) AS first_interaction_date, -- 觀測窗
口首日
COUNT(DISTINCT ga_session_id) AS historical_session_count,
IF(COUNT(DISTINCT ga_session_id) > 1, 1, 0) AS is_returning_user,
SUM(IFNULL(engagement_time_msec, 0)) / 1000 AS total_engaged_time_seconds,
ROUND(SAFE_DIVIDE(SUM(IFNULL(engagement_time_msec, 0)) / 1000, COUNT(DISTIN
CT ga_session_id)), 2) AS avg_session_engaged_time_seconds,
COUNTIF(event_name = 'view_item') AS view_item_count,
COUNTIF(event_name = 'page_view') AS page_view_count
FROM Filtered_Events
GROUP BY user_pseudo_id
),
Add_to_cart_Labels AS (
SELECT DISTINCT user_pseudo_id, 1 AS add_to_cart_label
FROM Raw_Data
WHERE event_name = 'add_to_cart'
),
Purchase_Revenue AS (
SELECT
user_pseudo_id,
SUM(ecommerce.purchase_revenue_in_usd) AS actual_purchase_revenue
FROM Raw_Data
WHERE event_name = 'purchase'
GROUP BY user_pseudo_id
),
View_Item_Features AS (
SELECT
user_pseudo_id,
COUNT(DISTINCT item_details.item_category) AS unique_categories_viewed,
AVG(IFNULL(item_details.price, 0)) AS avg_price_viewed
FROM Filtered_Events, UNNEST(items) AS item_details
WHERE event_name = 'view_item'
GROUP BY user_pseudo_id
),
Item_Repetition_Stats AS (

```

```

SELECT
    e.user_pseudo_id,
    IFNULL(item_details.item_id, item_details.item_name) AS item_identifier,
    COUNT(DISTINCT e.ga_session_id) AS item_view_sessions,
    COUNT(1) AS item_view_counts
FROM Filtered_Events AS e, UNNEST(e.items) AS item_details
WHERE e.event_name = 'view_item'
GROUP BY e.user_pseudo_id, item_identifier
),
User_Maxrep AS (
    SELECT
        user_pseudo_id,
        MAX(item_view_sessions) AS max_item_rep_sessions,
        MAX(item_view_counts) AS max_item_rep_views
    FROM Item_Repetition_Stats
    GROUP BY user_pseudo_id
)

SELECT
    F.* EXCEPT(page_view_count, view_item_count),

    -- 身分屬性 (全歷史、確定性、與下層一致)
    ID.traffic_source,
    ID.device_category,
    IFNULL(VIF.unique_categories_viewed, 0) AS unique_categories_viewed,
    IFNULL(VIF.avg_price_viewed, 0) AS avg_price_viewed,
    IFNULL(UM.max_item_rep_sessions, 0) AS max_item_rep_sessions,
    IFNULL(UM.max_item_rep_views, 0) AS max_item_rep_views,

    -- 這裡依舊可以使用 F.view_item_count 進行計算
    SAFE_DIVIDE(IFNULL(UM.max_item_rep_views, 0), F.view_item_count) AS item_focus_ratio,

    LN(IFNULL(F.historical_session_count, 0) + 1) AS log_historical_session_count,
    LN(IFNULL(F.total_engaged_time_seconds, 0) + 1) AS log_total_engaged_time_seconds,
    LN(IFNULL(F.avg_session_engaged_time_seconds, 0) + 1) AS log_avg_session_engaged_time_seconds,

    LN(IFNULL(VIF.unique_categories_viewed, 0) + 1) AS log_unique_categories_viewed,
    LN(IFNULL(VIF.avg_price_viewed, 0) + 1) AS log_avg_price_viewed,
    LN(IFNULL(UM.max_item_rep_sessions, 0) + 1) AS log_max_item_rep_sessions,
    LN(IFNULL(UM.max_item_rep_views, 0) + 1) AS log_max_item_rep_views,

    -- 觀測窗口跨度與頻率
    DATE_DIFF(F.last_interaction_date, F.first_interaction_date, DAY) AS days_in_dataset,
    SAFE_DIVIDE(F.historical_session_count, NULLIF(DATE_DIFF(F.last_interaction_date, F.first_interaction_date, DAY), 0)) AS session_frequency_per_day,
    SAFE_DIVIDE(F.view_item_count, F.historical_session_count) AS view_items_per_session,

    IF(E.add_to_cart_label = 1, 1, 0) AS cart_label,

```

```

IFNULL(PR.actual_purchase_revenue, 0) AS purchase_revenue,

-- split 用全歷史真實最後活躍日（兩表共用, 跨表一致）
CASE
  WHEN ID.user_last_active_date BETWEEN '2020-11-01' AND '2020-12-31' THEN 'TRAIN'
  WHEN ID.user_last_active_date BETWEEN '2021-01-01' AND '2021-01-21' THEN 'VALIDATION'
  ELSE 'TEST_HOLDOUT'
END AS data_split_label
FROM Base_Users AS F
INNER JOIN ${ref("user_identity")} AS ID ON F.user_pseudo_id = ID.user_pseudo_id
LEFT JOIN Add_to_cart_Labels AS E ON F.user_pseudo_id = E.user_pseudo_id
LEFT JOIN Purchase_Revenue AS PR ON F.user_pseudo_id = PR.user_pseudo_id
LEFT JOIN View_Item_Features AS VIF ON F.user_pseudo_id = VIF.user_pseudo_id
LEFT JOIN User_Maxrep AS UM ON F.user_pseudo_id = UM.user_pseudo_id
-- Unknown filter 改指向 user_identity (全歷史), 兩表完全一致
WHERE ID.traffic_source != 'Unknown'
AND ID.device_category != 'Unknown'

```

模型建構與評估 (Methodology & Model Performance)

在本專案的 MLOps 管線中，針對電商使用者的行為特徵，建立並評估了雙漏斗（加車、購買）的預測模型。所有基準數據皆來自嚴格隔離的時序測試集（Test Holdout），以確保評估指標的絕對客觀性。

▼ 時序資料切分策略 (Time-Series Data Split Strategy)

在電商場景的機器學習應用中，傳統的「隨機抽樣切分 (Random Split)」容易讓未來的特徵洩漏到過去，導致模型在驗證時產生虛高的幻覺。為了嚴格模擬真實世界的預測情境，本專案在資料管線的底層（如特徵工程表），依據使用者的**最後互動日期 (Last Interaction Date)**，將資料嚴格劃分為三個互不重疊的時間區塊：

- **訓練集 (Train Set) | 2020-11-01 至 2020-12-31 (共兩個月)**
 - **工程目的：**模型學習的基礎營地。演算法在此階段大量吸收消費者的歷史行為特徵，學習從「瀏覽、加車到購買」的深層意圖與非線性規律。
- **驗證集 (Validation Set) | 2021-01-01 至 2021-01-21 (共三週)**
 - **工程目的：**模型的「期中考」。主要用於演算法的超參數調優 (Hyperparameter Tuning) 以及尋找最佳的 F1-Score 決策門檻 (Threshold)。透過這組未參與訓練的近期資料，我們能客觀地修正模型，防止對歷史資料的過度擬合 (Overfitting)。
- **獨立盲測集 (Test Holdout) | 2021-01-22 至 2021-01-31 (最後十天)**
 - **工程目的：**這組資料在模型訓練、調參、尋找門檻的整個開發過程中被完全實體隔離。專案最終呈現的評估矩陣 (AUC、F1-Score) 皆產出自這組未知的盲測資料。

模型比較與最終選擇

針對 Logistic Regression、Random Forest 與 XGBoost 進行評估。

第一階段：購物車模型 (Cart Models) 評估

目標：在純瀏覽階段，預測使用者是否會將商品加入購物車。

模型演算法	Accuracy	F1 Score	Log Loss	Precision	Recall	ROC AUC
XGBoost	0.76	0.21	0.47	0.62	0.12	0.79
Logistic Regression	0.70	0.51	0.53	0.44	0.62	0.77

Random Forest	0.70	0.51	0.53	0.43	0.60	0.77
---------------	------	------	------	------	------	------

數據洞察

三模型 ROC-AUC：XGBoost 0.79（最高）、Logistic Regression 0.77、Random Forest 0.77，差距 0.02。**ROC-AUC 為比較主軸**（F1/Recall 受 0.5 固定門檻壓低，不反映真實判別力，在最優門檻下指標將正常化）：

- **XGBoost**：ROC-AUC（0.79）與 Log Loss（0.47）最佳。Recall（0.12）與 F1（0.21）極低——因 AUTO_CLASS_WEIGHTS=FALSE 下模型輸出校準機率，~20% base rate 的多數預測落在 0.5 以下；最優門檻下 recall 正常。
- **Logistic Regression**：Recall（0.62）與 F1（0.51）最高（AUTO_CLASS_WEIGHTS=TRUE 推高正類預測）。
- **Random Forest**：Accuracy（0.70）、F1（0.51）與 LR 持平；Recall（0.60，4x oversampling 所致）。

商業解讀

上層消費者行為充滿雜訊（隨意點擊、跨站比價），真實加車意圖弱且稀疏。XGBoost 的梯度提升架構能在高維、雜訊大的特徵空間中有效捕捉非線性訊號。現行採 AUTO_CLASS_WEIGHTS=FALSE 輸出校準機率——F1/Recall 在 0.5 門檻下偏低，需以最優門檻重算以反映真實效能。

第二階段：購買模型 (Purchase Models) 評估

目標：在加入購物車後、結帳前，預測使用者最終是否會完成購買。

模型演算法	Accuracy	F1 Score	Log Loss	Precision	Recall	ROC AUC
Random Forest	0.74	0.66	0.50	0.57	0.77	0.83
XGBoost	0.74	0.58	0.56	0.61	0.55	0.78
Logistic Regression	0.70	0.28	0.58	0.60	0.18	0.69

數據洞察

三模型 ROC-AUC：Random Forest 0.83（最高）、XGBoost 0.78、Logistic Regression 0.69，差距明顯擴大（RF vs XGB: +0.05）。

- **Random Forest**：ROC-AUC（0.83）、F1（0.66）、Recall（0.77）、Log Loss（0.50）均最佳。高 Recall 源於 3x oversampling——訓練機率偏高但整體排序力最強。
- **XGBoost**：ROC-AUC（0.78）居中，Precision（0.61）最高；val→test 降幅（0.83→0.78）略高於 RF（0.86→0.83），顯示 HPO 對較小 purchase dataset 的 validation 窗口略有偏合。
- **Logistic Regression**：Recall（0.18）與 F1（0.28）極低——AUTO_CLASS_WEIGHTS=FALSE + ~31% base rate 導致校準機率在 0.5 以下；ROC-AUC（0.69）最低，特徵組合在購買任務的判別力有限。

商業解讀

加車後的母群意圖較上層集中，但購買決策本質是多因素的——互動深度、購物車規模與商品瀏覽行為共同作用，而非由單一訊號決定。這種多因素、帶交互的結構，正適合 XGBoost 的非線性與交互捕捉能力，也是它在此階段能維持與主流模型同級表現的原因。

最終 MLOps 部署決策與核心理由

兩個漏斗均部署 XGBoost，選型以 ROC-AUC 為主要依據。

1. **上層**：效能明確支持 XGBoost——ROC-AUC（0.79）最高、Log Loss（0.47）最低；LR 與 RF 並列 0.77，差距 0.02。
2. **下層**：效能不再打平——RF ROC-AUC（0.83）高於 XGBoost（0.78）達 0.05，RF 為最強購買預測模型；但雙漏斗統一採 XGBoost，純為 MLOps 架構一致性（簡化 Dataform 管線維護）。此為已知效能折衷，後續可考慮下層改用 RF 追回 0.05 ROC-AUC。
3. **類別不平衡處理**：XGBoost 與 LR purchase 採 `AUTO_CLASS_WEIGHTS = FALSE` 以輸出校準機率（機率具商業語意）；LR cart 採 TRUE；RF 兩漏斗皆採 GENERATE_ARRAY oversampling（BQML RF 不支援 AUTO_CLASS_WEIGHTS）。F1/Recall 在 0.5 門檻下受不平衡壓低，不反映真實效能——以 ROC-AUC 為主要選型依據。

4. **架構一致性**：兩漏斗統一使用 XGBoost，簡化 Dataform 管線維護，無需為不同漏斗維護不同的模型邏輯與參數集。

▼ 點此展開：「XGBoost 加車模型訓練」完整 SQLX 原始碼

```
config {
  type: "operations",
  schema: "ga4_ml_us",
  hasOutput: true,
  dependencies: ["ga4_features_cart"],
  name: "predict_add_to_cart_model",
  description: "進階模型：XGBoost"
}
CREATE OR REPLACE MODEL ${self()}
TRANSFORM(
  cart_label,
  ML.STANDARD_SCALER(log_total_engaged_time_seconds) OVER() AS log_total_engaged_time_seconds,
  ML.STANDARD_SCALER(log_unique_categories_viewed) OVER() AS log_unique_categories_viewed,
  ML.STANDARD_SCALER(log_avg_price_viewed) OVER() AS log_avg_price_viewed,
  ML.STANDARD_SCALER(log_max_item_rep_views) OVER() AS log_max_item_rep_views,
  ML.STANDARD_SCALER(item_focus_ratio) OVER() AS item_focus_ratio,
  ML.STANDARD_SCALER(days_in_dataset) OVER() AS days_in_dataset,
  ML.STANDARD_SCALER(session_frequency_per_day) OVER() AS session_frequency_per_day,
  ML.STANDARD_SCALER(view_items_per_session) OVER() AS view_items_per_session,
  device_category,
  traffic_source,
  is_returning_user,
  hpo_split_col
)
OPTIONS(
  model_type='BOOSTED_TREE_CLASSIFIER',
  input_label_cols=['cart_label'],
  DATA_SPLIT_METHOD = 'CUSTOM',
  DATA_SPLIT_COL = 'hpo_split_col',
  AUTO_CLASS_WEIGHTS = TRUE,
  ENABLE_GLOBAL_EXPLAIN = TRUE,
  num_trials = 20,
  max_parallel_trials = 2,
  hparam_tuning_objectives = ['ROC_AUC'],
  LEARN_RATE = HPARAM_RANGE(0.01, 0.3),
  MAX_TREE_DEPTH = HPARAM_CANDIDATES([4, 6, 8, 10]),
  MIN_TREE_CHILD_WEIGHT = HPARAM_RANGE(1, 10),
  model_registry = 'vertex_ai',
  vertex_ai_model_id = 'ga4_cart_model',
  vertex_ai_model_version_aliases = ['xgb']
) AS
SELECT
  log_total_engaged_time_seconds,
  log_unique_categories_viewed,
  log_avg_price_viewed,
  log_max_item_rep_views,
```


```

item_focus_ratio,
days_in_dataset,
session_frequency_per_day,
view_items_per_session,
is_returning_user,
device_category,
traffic_source,
user_pseudo_id,
cart_label,
IF(data_split_label = 'VALIDATION', 'EVAL', 'TRAIN') AS hpo_split_col
FROM ${ref("ga4_features_cart")}
WHERE view_item_count > 0
AND data_split_label IN ('TRAIN', 'VALIDATION')

```

模型可解釋性分析 (SHAP Feature Attribution)

為了解開預測模型的「黑盒子」，本專案導入了 SHAP (SHapley Additive exPlanations) 演算法，量化並拆解了促成「加車」與「購買」的關鍵驅動因子。



上層漏斗：探索廣度決定加車意圖

數據觀察

影響加車的最主要特徵是「瀏覽不重複商品分類數」，是第二名約 3.4 倍，主導地位仍壓倒性。第二名是「是否回訪客」，顯示曾回訪的用戶具有額外的加車傾向。其後特徵（單品專注度、總互動時間、瀏覽商品平均價格.....）皆 ≤ 0.05 ，差距懸殊。

商業解讀

- **強化跨分類推薦以延伸探索路徑：**驅動加車的是跨越不同商品分類的探索廣度，不是單純瀏覽頁數。應在分類頁／商品頁主動推薦相關但不同類別的商品（「搭配這個的人也買了.....」），誘導用戶跨越分類邊界。
- **鎖定回訪用戶做精準觸達：**曾回訪的用戶加車意圖顯著高於首訪——他們帶著記憶回來，不是隨機流量。觸及策略可透過 push 通知或再行銷廣告主動喚回，不必等用戶自然重返；「最近瀏覽」功能同樣有助降低回訪後的搜尋摩擦。

下層漏斗：商品考量深度主導，多重行為信號輔助

數據觀察

最主要特徵是「購物車平均單品數量」，主導地位明確。第二名是「單品最大總重複瀏覽數 (MAXREP)」，顯示反覆盯著特定商品的猶豫行為是強力購買訊號。其後依序為「購物車總金額」、「每次造訪平均瀏覽商品數」、「總互動時間」。

商業解讀

- **購買由「總投入時間 + 購物車規模／金額」共同驅動：**會購買的用戶是整體投入更深、且購物車內容更多／更貴的人，而非反覆盯單一商品。

- 以「高互動時間 + 高購物車金額」作為觸發條件：這個組合對應模型最強的兩類訊號，作為挽回名單的優先級，精準度高於廣撒。


💰 動態決策門檻與分眾挽回策略 (Dynamic Targeting & Revenue Recovery)

為避免「盲目發券」造成的補貼浪費 (Cannibalization)，本專案不採固定 0.5 閾值，改以 SQL 自動計算最大化 F1-Score 的動態決策門檻。據此將流失用戶劃為高／中／低三層。手法選擇與成本經濟是獨立的下游層，依各層特性（自然轉換率代表的「成交接近度」、客單價、規模）配對：介入強度 $\propto$ 需要克服的摩擦，且只投在夠有反應的層。

介入手法有顯性成本階梯：提醒信 \$0 < 免運券 約 \$6 < 9 折券 約 \$8（以加車層 AOV \$80 計）；各層是否值得投放由兩個量決定——每人期望漏損（券面成本 $\times$ 自然轉換率）與打平所需 uplift（見各層補貼經濟推導）。各層以「潛在挽回營收上限（人數 $\times$ AOV）」估算機會規模——此為 100% 轉換的上界，真實可挽回額需以 A/B 測 uplift 後確認。

加車漏斗 (Cart Funnel)

加車用戶分群營收貢獻佔比



加車用戶分群

行銷受眾分級	基準客單價 (USD)	潛在挽回營收上限 (USD)	營收貢獻佔比 (%)	目標受眾規模 (人)	自然購買率
1. 1_高潛力加車 (發送 9 折券)	80	36,342.70	14.43	454	0.11
2. 2_中潛力加車 (觀察或發送免運券)	69	45,625.65	18.11	665	0.07
3. 3_低潛力觀察 (暫不發放行銷資源)	150	169,966.25	67.46	1135	0.01

門檻：高潛力 > 0.35、中潛力 0.21-0.35、低潛力 < 0.21。流失總數 2,254。

高潛力加車 (分數 > 0.35) → 9 折券

- 數據：454 人（佔流失 20.1%），自然購買率 11%，客單價 \$80，潛在挽回上限 \$36,342.70（貢獻 14.43%）。
- 策略：這群用戶被預測有高加車傾向卻遲遲未行動，摩擦在「從探索收斂到首次承諾」（對應上層 SHAP：探索廣度主導，是否回訪客為第二訊號——回訪者意圖更強但仍未加車）。9 折券的作用是壓低首次承諾門檻，給仍在觀望的探索者一個立即行動的理由；此層意圖最強（11%），故把最強的價格槓桿集中於此。
- 補貼經濟（為什麼對自然率 11% 的高潛力層用最強誘因）：自然購買率 11%，每人期望補貼成本 $\approx 11\% \times \$8$ （ $\$80 \times 10\%$ ） $\approx \$0.88$ 。設毛利率 m 、折扣深度 $d=10\%$ ，打平所需 uplift = $11\% \times d \div (m - d)$ ：

毛利率假設 m	打平所需 uplift	目標購買率
30%	+5.5pp	16.5%
40%	+3.67pp	14.67%
50%	+2.75pp	13.75%

- 解讀：即使取最保守的 30% 毛利，購買率從 11% 拉到 16.5% 即打平。毛利率假設 40% $\pm$ 10pp 有公開基準支撐：美國上市服飾業毛利約 54-57%、品牌周邊經銷商約 36-40%，Google 周邊商品店性質介於兩者之間。公式同時給出折扣深度上界： d 必須 $< m$ ——9 折在任何合理毛利下皆安全，7 折在 30% 毛利下已是負毛利券。（假設：僅成交者兌換、AOV 不因折扣改變、自然率以整段購買傾向為代理。）
- 註：9 折是「深度假設」而非結論。高潛力自然購買率（11%）高於中潛力（7%），兩層差異既在意圖強度亦在規模；A/B 除驗證高／中手法切分外，亦應納入折扣深度階梯（95 折 vs 9 折）。

中潛力加車 (分數 0.21-0.35) → 觀察 / 免運券


- 數據：665 人（29.5%），自然購買率 7%，客單價 \$69，上限 \$45,625.65（貢獻 18.11%）。

- 策略：意圖略低於高潛力（7% vs 11%），但規模更大（665 人 vs 454 人），列為次要投放。採較輕介入（免運券）或先觀察，保留預算彈性；免運讓利幅度小於 9 折，適合對「意圖差異明確但預算偏好保守」的群組試水。

低潛力觀察（分數 < 0.21）→ 不投

- 數據：1,135 人（50.4%，人數最多），自然購買率僅 1%，客單價 \$150，上限 \$169,966.25（貢獻 67.46%）。
- 策略：止損。貢獻 67.46% 是「人數最多 × 客單價最高（\$150）」撐起的上限假象——自然購買率僅 1%，補貼邊際效益高度不確定。低潛力的判斷是「購買意願」非「消費能力」。預算保留給高／中潛力。

結帳漏斗 (Purchase Funnel)



門檻：高潛力 > 0.50、中潛力 0.30–0.50、低潛力 < 0.30。流失總數 533。

高潛力結帳挽回（分數 > 0.50）→ 提醒信

- 數據：94 人（17.6%），自然購買率 60%（三層最高），客單價 \$88.41，上限 \$8,310.54（貢獻 23.9%）。
- 策略：這群棄單者最接近成交（購買傾向 60%），對小推力最敏感、摩擦最低。一封「購物車商品還在等您」的提醒信很可能就足以促成結帳，先用最低成本的手法；若 A/B 顯示不足再升級。不需在最可能自己回頭的人身上灑券。

中潛力結帳挽回（分數 0.30–0.50）→ 免運券

- 數據：261 人（49%，人數最多），自然購買率 27%，客單價 \$69.42，上限 \$18,118.62（貢獻 52.1%）。
- 策略：意圖中等、仍在猶豫，單純提醒可能不足。免運券移除「運費痛點」——結帳放棄的常見主因——給猶豫者一個具體的成交理由。是本次主要的券預算投放標的。
- 補貼經濟：免運名義上是「較輕」的手法，但這層自然購買率高達 24%，白拿補貼的漏損反而最大——每人期望補貼 $\approx 27\% \times \$6 \approx \1.62 ，約為加車 9 折層（\$0.88）的 1.84 倍。假設免運成本 $s = \$6$ 、AOV \$69.42，打平所需 uplift $= 27\% \times s \div (AOV \times m - s)$ 如下表——打平門檻遠高於 9 折層。這正是 A/B 優先序把「免運是否值得」列為優先測試的量化理由。

毛利率假設 m	打平所需 uplift	目標購買率
30%	+10.93pp	37.93%
40%	+7.44pp	34.44%
50%	+5.65pp	32.65%

- 同一組公式也反向解釋了高潛力層（自然率 60%）為何只發信不發券：自然率越高，同一張券的漏損越貴。
- 免運是二元手法、無深度階梯，A/B 應改測手法階梯：免運 vs 小額折抵（\$5 off）vs 純提醒信。

低潛力觀察（分數 < 0.30）→ 不投

- 數據：178 人 (33.4%)，自然購買率 7%，客單價 \$ 46.89，上限 \$ 8,346.42 (貢獻 24%)。
- 策略：意圖最弱 (7%)、客單價最低 (\$ 46.89)，補貼 ROI 難正當化。保留常規電子報被動觸達，待 A/B 再評估是否介入。

▼ 後續驗證：分層 A/B Holdout (Incrementality Test)

以上手法配置是基於分群特性的假設；真正的增量效果 (uplift) 只有實驗能定。設計：

1. 在每個有投放的分層內部隨機切兩組：treatment (發指派手法) vs control (完全不接觸)。
2. control 組的轉換率 = 該層真實的「不介入」基線 (取代「整段購買率」這個代理)。
3. $\text{treatment} - \text{control} = \text{該手法在該層的 uplift (真正的增量)}$ 。
4. 要比手法，就在同一層開多批次 (例：加車高潛力同跑 9 折批次、免運批次、control)，比各批次的增量。
5. 優先序：先測「價值高 + 最不確定」的格——購買中潛力 (免運是否值得：打平門檻最高的一格)、加車高／中潛力 (9 折 vs 免運 vs 觀察)，並在加車高潛力內加測折扣深度階梯 (95 折 vs 9 折)。
6. 前置：做 power calculation——各層樣本小，需先估「要偵測多大 uplift、需多少樣本」，不足就跨期累積，否則跑了也是雜訊。

⚠ 限制與未來展望 (Limitations & Future Work)

專案限制：

雖然本專案透過嚴格的時序切分與雙軌模型架構確保了預測的穩定性，但在實務落地上仍有以下侷限需要克服：

• 資料時間跨度與季節性偏差 (Seasonality Bias)

訓練與測試資料集中在 2020 年 11 月至 2021 年 1 月 (約三個月)，涵蓋黑五、聖誕等高轉換節點。模型可能學到促銷期的高活躍特徵，若套用於淡季，預測機率與門檻可能需重新校準。購買漏斗 XGBoost Validation AUC (0.83) 高於 Test (0.78)，部分源於 HPO 直接以 validation AUC 為最佳化目標而偏樂觀，部分為時間推移的輕微分布偏移——test 0.78 才是無偏估計，屬已知穩定性限制。RF (Validation 0.86 → Test 0.83) 降幅較小，顯示無 HPO 反而泛化更穩。

• 機會規模為上界；自然率與手法配置皆為待驗證的代理／假設

潛在挽回營收以「人數 × 分層 AOV」呈現為上限 (機會上界)，本專案不以淨利作為對外決策數字——因為淨利完全取決於假設 uplift (無法觀察、只有 A/B 能測量)，易誤導。殘留限制：(a) 分層 AOV 來自轉換者，套用於被挽回的猶豫用戶時其購買金額未必相同；(b) 報表的「自然購買率」是整段 (含已購買者) 的購買傾向，作為優先級／校準訊號，而非被鎖定棄單者的真實 do-nothing 率 (後者 ≈ 0)，不可直接當「保底營收」解讀。

• 門檻中潛力下界為啟發式；手法配置為特性導向的假設

決策門檻採 F1-max，中潛力下界沿用門檻 × 0.6 的啟發式。限制在於：(a) × 0.6 為啟發值，非由經濟學推導；(b) 「哪一層發哪種券」是基於分群特性 (成交接近度、摩擦) 的假設，非實測最優——真正的最適手法需各層的實測 uplift 才能定，介入成本、基準轉換率與 uplift 三者缺乏 A/B 時無法解耦——分眾策略中的 breakeven 推導能給出「打平所需 uplift」門檻、縮小不確定範圍，但實際 uplift 仍只有實驗能量測，且毛利率 (40% ± 10pp) 與免運成本 (\$ 6) 均為外部假設參數。

未來展望：

演進至真實的提升模型 (Uplift Modeling)

未來從「預測轉換機率 (Propensity Model)」升級為「預測增額機率 (Uplift Model)」，透過分層 A/B holdout 收集對照組 (不介入) 與實驗組 (發券) 資料，讓模型直接學習介入與否的因果效應，精準找出「只有拿到誘因才會購買」的勸誘客 (Persuadables)。A/B 的對照組同時補上目前兩項核心缺口：各層真實的 do-nothing 率 (取代整段購買率的代理)，以及各手法在各層的 uplift (讓手法配置從「特性導向假設」升級為實測最優)。

推動即時串流預測 (Real-time In-session Prediction)

目前架構偏向批次推論 (Batch Inference)，針對已流失用戶事後挽回。未來目標是導入串流處理 (如 Kafka / Spark Streaming)，在用戶仍在瀏覽的當下即時運算互動特徵，若偵測到加車或結帳意圖快速衰退，即時於網頁端觸發限時優

惠，達成真正的「當下攔截」而非事後補救。

個人化誘因最佳化 (Personalized Incentive Allocation)

將行銷動作本身納入模型決策範疇。除預測機率外，系統未來應能依用戶的毛利貢獻度與介入成本動態決定誘因類型（免運券、折扣碼或僅系統推播），實現「對的人、對的時間、最低成本的有效誘因」。搭配定期再訓練機制，確保每次重訓後門檻同步以新分數重新校準，避免分層邊界因分數分布漂移而失準。

Reference:

Kukar-Kinney, M., & Close, A. G. (2010). The determinants of consumers' online shopping cart abandonment. *Journal of the Academy of Marketing Science*, 38(2), 240–250.

Moe, W. W. (2003). Buying, Searching, or Browsing: Differentiating Between Online Shoppers Using In-Store Navigational Clickstream. *Journal of Consumer Psychology*, 13(1&2), 29–39.

Sakar, C. O., Polat, S. O., Katircioglu, M., & Kastro, Y. (2018). Real-time prediction of online shoppers' purchasing intention using multilayer perceptron and LSTM recurrent neural networks. *Neural Computing and Applications*. <https://doi.org/10.1007/s00521-018-3523-0>.

Wu, J., Shi, L., Yang, L., Niu, X., Li, Y., Cui, X., Tsai, S.-B., & Zhang, Y. (2021). User Value Identification Based on Improved RFM Model and K-Means++ Algorithm for Complex Data Analysis. *Wireless Communications and Mobile Computing*, 2021. <https://doi.org/10.1155/2021/9982484>.